

BENCHMARK AZURE AI · INSTRUMENTATION MULTI-RÉGION

Rapport d'analyse — stabilité des déploiements

9 modèles, régions sweden & francecentral · échantillon du 10 au 14 juillet 2026

APPELS ANALYSÉS

16 820

sur 16 842 lignes de log

MODÈLES SURVEILLÉS

9

claude-opus-4-7 retiré du run le 10/07

PIRE TAUX D'ERREUR

37,0 %

Phi-4-mini-instruct

LATENCE MÉDIANE LA + HAUTE

4 226 ms

claude-sonnet-4-6

Récapitulatif par modèle

Latences calculées uniquement sur les appels réussis — un timeout à 30 000 ms n'entre pas dans la moyenne.

MODÈLE	APPELS	TAUX D'ERREUR	LATENCE MOYENNE	LATENCE MÉDIANE
Phi-4-mini-instruct	1 870	37,0 %	3 647,0 ms	2 361,5 ms
DeepSeek-V4-Pro	1 870	9,1 %	4 436,4 ms	2 813,6 ms
Kimi-K2.6	1 870	4,0 %	4 689,0 ms	3 991,7 ms
DeepSeek-V3.2	1 870	3,3 %	2 120,5 ms	1 904,2 ms
gpt-5.4	1 870	3,1 %	1 576,1 ms	1 656,3 ms
gpt-5.4-mini	1 870	2,9 %	1 066,9 ms	1 045,8 ms
gpt-5.4-nano	1 870	2,7 %	1 385,9 ms	1 281,4 ms
claude-sonnet-4-6	1 860	2,7 %	4 104,1 ms	4 226,6 ms
claude-haiku-4-5	1 860	2,7 %	2 285,4 ms	2 440,4 ms

